Анализ вакансий Java-разработчиков

Обработка данных с использованием RustFS, MapReduce и DuckDB

Отчёт подготовлен 21.10.2026

Репозиторий: github.com/tayamaken/java-vacancy-analysis

1. Цель и данные

Цель проекта — обработать вакансии Java-разработчиков, определить часто встречающиеся навыки и комбинации навыков, сравнить результаты двух независимых реализаций, оценить производительность чтения чанками и исследовать различия между регионами и зарплатными группами.

Подготовленный набор содержит 6 907 вакансий. Подготовленный CSV занимает 25 775 271 байт (около 25,8 МБ). Исходный файл расположен локально по пути D:\ITMO\DataEng\rustfs-data\it_vacancies_2024.csv и занимает около 848 МБ. Исходные данные не включаются в Git.

2. Архитектура и хранение

RustFS используется как S3-совместимое объектное хранилище. Endpoint: http://localhost:9000, bucket: hh-lake. Подготовленный набор хранится по ключу java_developer_csv/java_vacancies.csv. Результаты MapReduce размещаются под префиксом mapreduce_chunked/.

Основные компоненты проекта: src/mapreduce_chunked.py — MapReduce с чтением чанками; src/duckdb_analysis.py — независимый SQL-подсчёт; src/compare_results.py — сравнение; отдельные скрипты отвечают за зарплаты и региональные срезы. Локальные таблицы находятся в каталоге results/.

3. Результаты MapReduce

Обработка выполнена с размерами чанков 256 КБ, 1 МБ и 4 МБ. Во всех вариантах обработано 6 907 вакансий. Получены 1 343 уникальных навыка, 20 635 уникальных пар и 137 489 уникальных троек. Число троек существенно больше числа навыков, поскольку комбинации могут составляться из множества разных сочетаний навыков одной вакансии.

Сводка MapReduce

Источник: results/mapreduce_chunked/profiling.csv. Всего строк: 3.

Примечание: показаны первые шесть столбцов из 11.

chunk_size	chunk_bytes	rows_processed	rows_with_skills	unique_skills	unique_pairs
256KB	262144	6907	4731	1343	20635
1MB	1048576	6907	4731	1343	20635
4MB	4194304	6907	4731	1343	20635

Пример результата: навыки

Источник: results/mapreduce_chunked/256KB/skills.csv. Всего строк: 1343.

skill	vacancy_count
java	3751
spring framework	2091
postgresql	1839
sql	1271
git	1265
spring boot	1010
kafka	951
docker	776
javascript	763
hibernate orm	671
Показаны первые 10 из 1343 строк.	

Пример результата: пары навыков

Источник: results/mapreduce_chunked/256KB/skill_pairs.csv. Всего строк: 20635.

skill_1	skill_2	vacancy_count
java	spring framework	1966
java	postgresql	1627
postgresql	spring framework	1113
java	sql	1078
git	java	961
java	spring boot	947
java	kafka	884
docker	java	642
Показаны первые 8 из 20635 строк.		

Пример результата: тройки навыков

Источник: results/mapreduce_chunked/256KB/skill_triples.csv. Всего строк: 137489.

skill_1	skill_2	skill_3	vacancy_count
java	postgresql	spring framework	1054
git	java	spring framework	596
java	spring framework	sql	533
hibernate orm	java	spring framework	529
git	java	postgresql	518
java	kafka	postgresql	511
java	kafka	spring framework	499
java	postgresql	spring boot	483
Показаны первые 8 из 137489 строк.			

4. Проверка через DuckDB

Для проверки корректности выполнен независимый подсчёт с помощью DuckDB и SQL. Скрипт compare_results.py сравнил CSV MapReduce и DuckDB. Во всех трёх наборах не обнаружено различий ни по составу строк, ни по частотам.

Пример SQL-результата

skill	vacancy_count
java	3751
spring framework	2091
postgresql	1839
sql	1271
git	1265
spring boot	1010
kafka	951
docker	776
Показаны первые 8 из 1343 строк.	

Проверенные размеры результатов: 1 343 навыка, 20 635 пар и 137 489 троек. Совпадение двух независимых реализаций является подтверждением корректности подсчёта на данном наборе данных.

5. Производительность

Каждый размер чанка был измерен в трёх запусках. В таблице приведены сводные значения из profiling_summary.csv. Пиковая память отражает наблюдавшееся потребление памяти процесса в условиях этого эксперимента.

Сводная производительность

Источник: results/mapreduce_chunked/profiling_summary.csv. Всего строк: 3.

Примечание: показаны первые шесть столбцов из 7.

chunk_size	runs	avg_seconds	min_seconds	max_seconds	avg_peak_rss_mb
256KB	3	1,0344	0,975	1,0857	84,29
1MB	3	1,826	1,714	1,9118	84,63
4MB	3	5,6643	5,1673	6,0239	86,46

Девять повторных измерений

Источник: results/mapreduce_chunked/profiling_repeated_measurements.csv. Всего строк: 9.

run	chunk_size	elapsed_seconds	peak_rss_mb	read_chunks
1	256KB	1,0426	84,95	99
1	1MB	1,8522	84,77	25
1	4MB	5,1673	85,28	7
2	256KB	1,0857	84,05	99
2	1MB	1,9118	84,86	25
2	4MB	6,0239	87,04	7
3	256KB	0,975	83,87	99
3	1MB	1,714	84,26	25
3	4MB	5,8018	87,07	7

В проведённом эксперименте среднее время для чанка 256 КБ составило около 1,0344 с, для 1 МБ — 1,8260 с, для 4 МБ — 5,6643 с. Средняя пиковая память составила около 84,29; 84,63 и 86,46 МБ соответственно. Количество операций чтения уменьшалось с 99 до 25 и 7. Несмотря на меньшее число чтений, большие чанки оказались медленнее в данной реализации и среде. Этот результат нельзя обобщать на другие системы без дополнительных экспериментов.

6. Региональный анализ

В региональном сравнении рассмотрены Москва, Санкт-Петербург и Новосибирск. Число вакансий составляет 3 376, 935 и 308 соответственно. Поэтому доли навыков в Новосибирске основаны на меньшей выборке и могут быть менее устойчивыми.

Навыки по регионам

Источник: results/regions/skills_by_region.csv. Всего строк: 1645.

region	skill	vacancy_count	region_vacancies	percent_of_region_vacancies
Москва	java	1697	3376	50.27
Москва	spring framework	964	3376	28.55
Москва	postgresql	848	3376	25.12
Москва	sql	548	3376	16.23
Москва	kafka	522	3376	15.46
Москва	spring boot	514	3376	15.23
Москва	git	499	3376	14.78
Москва	docker	379	3376	11.23
Москва	javascript	296	3376	8.77
Москва	kubernetes	263	3376	7.79
Москва	kotlin	260	3376	7.7
Москва	rest	251	3376	7.43
Москва	hibernate orm	243	3376	7.2
Москва	rabbitmq	183	3376	5.42
Москва	hibernate	162	3376	4.8
Москва	spring	160	3376	4.74
Москва	react	151	3376	4.47
Москва	apache kafka	151	3376	4.47
Показаны первые 18 из 1645 строк.				

Зарплаты по регионам

Источник: results/salary/salary_by_region.csv. Всего строк: 3.

Примечание: показаны первые шесть столбцов из 7.

region	all_vacancies	rur_salary_from_count	rur_salary_from_median	rur_salary_to_count	rur_salary_to_median
Москва	3376	507	200000.0	480	250000.0
Новосибирск	308	64	150000.0	51	220000.0
Санкт-Петербург	935	193	140000.0	158	235000.0

7. Качество зарплатных данных

В 5 219 из 6 907 вакансий зарплата не указана (75,56%). Значения gross отсутствуют в 5 219 строках; 1 173 строки имеют gross=false, а 515 — gross=true. Поэтому анализ зарплат выполняется на подмножестве объявлений с доступными данными и не описывает весь рынок без смещения.

Качество зарплат

Источник: results/salary/salary_quality.csv. Всего строк: 9.

metric	count	percent_of_all_vacancies
salary_from_filled	1372	19.86

metric	count	percent_of_all_vacancies
salary_to_filled	1149	16.64
both_salary_fields_filled	833	12.06
only_salary_from_filled	539	7.8
only_salary_to_filled	316	4.58
both_salary_fields_empty	5219	75.56
invalid_salary_from_values	0	0.0
invalid_salary_to_values	0	0.0
salary_from_greater_than_salary_to	0	0.0

Распределение валют

Источник: results/salary/salary_by_currency.csv. Всего строк: 6.

currency	vacancy_count	percent_of_all_vacancies
(не указана)	5219	75.56
RUR	1614	23.37
USD	60	0.87
EUR	10	0.14
KZT	3	0.04
BYR	1	0.01

Сводная статистика зарплат

Источник: results/salary/salary_numeric_summary.csv. Всего строк: 10.

Примечание: показаны первые шесть столбцов из 9.

currency	salary_field	count	min	p25	median
BYR	salary_from	1	2500.0	2500.0	2500.0
BYR	salary_to	1	4000.0	4000.0	4000.0
EUR	salary_from	9	500.0	3000.0	3000.0
EUR	salary_to	9	800.0	3500.0	4700.0
KZT	salary_from	3	150000.0	150000.0	150000.0
KZT	salary_to	2	550000.0	550000.0	550000.0
RUR	salary_from	1308	140.0	70000.0	140000.0
RUR	salary_to	1104	300.0	100039.0	203500.0
USD	salary_from	51	800.0	1000.0	2800.0
USD	salary_to	33	1000.0	3500.0	4000.0

Диапазоны зарплат

Источник: results/salary/salary_ranges.csv. Всего строк: 5.

currency	vacancies_with_both_bounds	median_salary_from	median_salary_to	median_range_width	inverted_ranges
BYR	1	2500.0	4000.0	1500.0	0
EUR	8	3000.0	4500.0	1000.0	0
KZT	2	150000.0	550000.0	400000.0	0
RUR	798	120000.0	180000.0	50000.0	0
USD	24	3000.0	4500.0	1500.0	0

8. Навыки и зарплата

Для зарплатного анализа использовались вакансии с зарплатой в RUB и пригодными данными о навыках. Медианы для комбинаций навыков являются описательными ассоциациями: они не доказывают, что наличие конкретного навыка вызывает рост или снижение зарплаты. На результаты влияют уровень специалиста, регион, размер выборки, тип компании и полнота объявления. Малочисленные группы следует интерпретировать особенно осторожно.

Навыки и зарплаты

Источник: results/salary/skill_combinations/skills_salary.csv. Всего строк: 175.

Примечание: показаны первые шесть столбцов из 7.

combination	vacancy_count	median_salary	mean_salary	overall_median_salary	difference_from_overall
keycloak	5	400000.0	340000.0	165000.0	235000.0
jvm	5	375000.0	345000.0	165000.0	210000.0
backbone	5	367500.0	344500.0	165000.0	202500.0
microservices	31	300000.0	302016.13	165000.0	135000.0
elk	8	295000.0	282500.0	165000.0	130000.0
prometheus	6	282500.0	270833.33	165000.0	117500.0
jdbc	22	280000.0	242840.91	165000.0	115000.0
микросервисная архитектура	12	280000.0	262916.67	165000.0	115000.0
grafana	12	280000.0	259583.33	165000.0	115000.0
ci/cd	25	275000.0	236800.0	165000.0	110000.0
jms	9	275000.0	264444.44	165000.0	110000.0
jenkins	32	270000.0	241406.25	165000.0	105000.0
Показаны первые 12 из 175 строк.					

Пары навыков и зарплаты

Источник: results/salary/skill_combinations/pairs_salary.csv. Всего строк: 1498.

Примечание: показаны первые шесть столбцов из 7.

combination	vacancy_count	median_salary	mean_salary	overall_median_salary	difference_from_overall
hibernate + swagger	8	420000.0	349375.0	165000.0	255000.0
spring + spring framework	15	400000.0	323333.33	165000.0	235000.0
maven + microservices	10	400000.0	350000.0	165000.0	235000.0
kotlin + microservices	8	400000.0	362187.5	165000.0	235000.0
gradle + microservices	7	400000.0	327142.86	165000.0	235000.0
hibernate orm + kotlin	6	400000.0	341666.67	165000.0	235000.0
jenkins + kotlin	6	400000.0	357500.0	165000.0	235000.0
java + keycloak	5	400000.0	340000.0	165000.0	235000.0
keycloak + kubernetes	5	400000.0	340000.0	165000.0	235000.0
keycloak + postgresql	5	400000.0	340000.0	165000.0	235000.0
keycloak + spring boot	5	400000.0	340000.0	165000.0	235000.0
hibernate orm + rabbitmq	9	390000.0	347222.22	165000.0	225000.0
Показаны первые 12 из 1498 строк.					

Тройки навыков и зарплаты

Источник: results/salary/skill_combinations/triples_salary.csv. Всего строк: 4799.

Примечание: показаны первые шесть столбцов из 7.

combination	vacancy_count	median_salary	mean_salary	overall_median_salary	difference_from_overall
hibernate orm + rabbitmq + spring boot	5	450000.0	436000.0	165000.0	285000.0
hibernate + kotlin + spring boot	7	425000.0	312857.14	165000.0	260000.0
hibernate + java + swagger	8	420000.0	349375.0	165000.0	255000.0
apache maven + hibernate orm + rabbitmq	6	420000.0	409166.67	165000.0	255000.0
apache kafka + hibernate + rest	5	420000.0	370000.0	165000.0	255000.0
apache kafka + rest + sql	5	420000.0	370000.0	165000.0	255000.0
apache maven + soap + spring framework	5	420000.0	324000.0	165000.0	255000.0
apache kafka + docker + rest	5	420000.0	363000.0	165000.0	255000.0
apache kafka + java + soap	5	420000.0	363000.0	165000.0	255000.0
apache kafka + rabbitmq + soap	5	420000.0	363000.0	165000.0	255000.0
apache kafka + rabbitmq + spring	5	420000.0	363000.0	165000.0	255000.0
apache kafka + rest + soap	5	420000.0	363000.0	165000.0	255000.0
Показаны первые 12 из 4799 строк.					

9. Выводы и ограничения

• MapReduce позволил подсчитать частоты навыков, пар и троек при чтении данных чанками.

• Результаты MapReduce полностью совпали с независимым подсчётом DuckDB.

• В измерениях на этой машине чанки 256 КБ показали наименьшее среднее время, но это не универсальный вывод для любых данных и систем.

• Региональные результаты показывают различия в частоте упоминания навыков; размер выборки по регионам неодинаков.

• Большая доля вакансий не содержит зарплату. Зарплатные выводы основаны на неполном подмножестве и являются наблюдательными, а не причинными.

• Результаты зависят от качества исходных данных, нормализации названий навыков и выбранных параметров обработки.

Код и результаты проекта: https://github.com/tayamaken/java-vacancy-analysis